



UNIVERSIDADE
FEDERAL DO CEARÁ



Aprendizagem de Máquina

César Lincoln Cavalcante Mattos

2020

Agenda


- ① SVM linear com hard margin
- ② SVM linear com soft margin
- ③ SVM não-linear
- ④ Tópicos adicionais
- ⑤ Referências

Máquinas de Vetores Suporte

- **Problema:** Como realizar classificação linear binária (-1 ou 1)?

Máquinas de Vetores Suporte


- **Problema:** Como realizar classificação linear binária (-1 ou 1)?



$$\hat{y}_i = \begin{cases} -1, & \text{se } \sigma(\mathbf{w}^\top \mathbf{x}_i + b) < 0.5 \text{ ou } \mathbf{w}^\top \mathbf{x}_i + b < 0 \\ 1, & \text{se } \sigma(\mathbf{w}^\top \mathbf{x}_i + b) \geq 0.5 \text{ ou } \mathbf{w}^\top \mathbf{x}_i + b \geq 0 \end{cases}$$

Máquinas de Vetores Suporte

- **Problema:** Como realizar classificação linear binária (-1 ou 1)?



$$\hat{y}_i = \begin{cases} -1, & \text{se } \sigma(\mathbf{w}^\top \mathbf{x}_i + b) < 0.5 \text{ ou } \mathbf{w}^\top \mathbf{x}_i + b < 0 \\ 1, & \text{se } \sigma(\mathbf{w}^\top \mathbf{x}_i + b) \geq 0.5 \text{ ou } \mathbf{w}^\top \mathbf{x}_i + b \geq 0 \end{cases}$$


- **Problema:** A fronteira otimizada ficará próxima de uma das classes, por causa de sua dispersão.

Máquinas de Vetores Suporte

- **Ideia:** Focar nos dados próximos da região de separação das classes.


Máquinas de Vetores Suporte

- **Ideia:** Focar nos dados próximos da região de separação das classes.
- **Ideia:** Escolher uma fronteira com **máxima margem de separação**.



Máquinas de Vetores Suporte


- **Ideia:** Focar nos dados próximos da região de separação das classes.
- **Ideia:** Escolher uma fronteira com **máxima margem de separação**.



- **Vetores suporte:** Padrões próximos da fronteira e que a definem.

Máquinas de Vetores Suporte

- **Classificador de margem máxima:** Buscam uma fronteira de máxima margem de separação entre as classes.




$$\hat{y}_i = \begin{cases} -1, & \text{se } \mathbf{w}^\top \mathbf{x}_i + b \leq -1 \\ 1, & \text{se } \mathbf{w}^\top \mathbf{x}_i + b \geq 1 \\ \text{indefinido,} & \text{se } -1 < \mathbf{w}^\top \mathbf{x}_i + b < 1 \end{cases}$$

- **Condição equivalente:**

$$(\mathbf{w}^\top \mathbf{x}_i + b)y_i \geq 1$$

Máquinas de Vetores Suporte




- Considere dois pontos u, v sobre o plano $+1$:

$$\begin{aligned}w^\top u + b &= w^\top v + b = 1 \\w^\top (u - v) &= 0.\end{aligned}$$

- w é perpendicular ao plano $+1$ (e também ao plano -1).

Máquinas de Vetores Suporte



- Sejam \mathbf{x}_- , \mathbf{x}_+ pontos mais próximos entre si nos planos -1 e $+1$:

$$\mathbf{w}^\top \mathbf{x}_- + b = -1$$


$$\mathbf{w}^\top \mathbf{x}_+ + b = 1$$

$$\mathbf{w}^\top (\mathbf{x}_+ - \mathbf{x}_-) = 2$$

- A separação entre os pontos é tal que $d\mathbf{w} = \mathbf{x}_+ - \mathbf{x}_-$:

$$\mathbf{w}^\top d\mathbf{w} = 2 \rightarrow d = \frac{2}{\mathbf{w}^\top \mathbf{w}}.$$

Máquinas de Vetores Suporte



- A menor margem $M = \|\mathbf{x}_+ - \mathbf{x}_-\|$ entre os planos -1 e $+1$ será:

$$M = \|\mathbf{x}_+ - \mathbf{x}_-\| = \|d\mathbf{w}\|$$

$$M = d\sqrt{\mathbf{w}^\top \mathbf{w}}$$

$$M = \frac{2}{\mathbf{w}^\top \mathbf{w}} \sqrt{\mathbf{w}^\top \mathbf{w}}$$

$$M = \frac{2}{\sqrt{\mathbf{w}^\top \mathbf{w}}} = \frac{2}{\|\mathbf{w}\|}$$

Máquinas de Vetores Suporte

Formulação linear primal do SVM (*Support Vector Machine*)

- Busca os valores de \mathbf{w} e b ótimos tais que:
 - Classifique corretamente todos os exemplos de treinamento $(\mathbf{x}_i, y_i)_{i=1}^N$.
 - Maximize a menor margem $M = \frac{2}{\|\mathbf{w}\|}$ de separação entre as classes, o que equivale a minimizar $\mathbf{w}^\top \mathbf{w}$.
- Classificação binária linear como um problema de otimização com restrições lineares:

$$\begin{aligned} & \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s. a. } & (\mathbf{w}^\top \mathbf{x}_i + b)y_i \geq 1, \quad \forall i \in \{1, \dots, N\}. \end{aligned}$$

Máquinas de Vetores Suporte

- Podemos converter o problema de otimização com restrições em um sem restrições com termos de penalização:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + \text{penalização}.$$

Máquinas de Vetores Suporte

- Podemos converter o problema de otimização com restrições em um sem restrições com termos de penalização:

$$\min_{w,b} \frac{1}{2} \|\mathbf{w}\|^2 + \text{penalização}.$$

- Escolhemos as penalizações abaixo:

$$\max_{\alpha_i \geq 0} \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b)y_i] = \begin{cases} 0, & \text{se } (\mathbf{w}^\top \mathbf{x}_i + b)y_i \geq 1, \\ \infty, & \text{caso contrário,} \end{cases}$$

em que $\alpha_i|_{i=1}^N$ são **multiplicadores de Lagrange**.

Máquinas de Vetores Suporte

- Novo problema de otimização:

$$\min_{\mathbf{w}, b} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \max_{\alpha_i \geq 0} \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i] \right\}$$
$$\min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i] \right\}$$

Máquinas de Vetores Suporte

- Novo problema de otimização:

$$\min_{\mathbf{w}, b} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \max_{\alpha_i \geq 0} \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i] \right\}$$
$$\min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i] \right\}$$

- Note que para $(\mathbf{w}^\top \mathbf{x}_i + b) y_i \geq 1, \forall i$ (nenhuma restrição quebrada), teríamos:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

Máquinas de Vetores Suporte

- A otimização depende de uma função dos parâmetros, termo de viés e multiplicadores de Lagrange:

$$\min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}),$$

$$\mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i].$$

Máquinas de Vetores Suporte

- A otimização depende de uma função dos parâmetros, termo de viés e multiplicadores de Lagrange:

$$\min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}),$$

$$\mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i].$$

- Reordenamos os operadores min e max, criando um limiar inferior:

$$\max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}) \leq \min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}).$$

Máquinas de Vetores Suporte

- A desigualdade

$$\max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}) \leq \min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}).$$

torna-se uma igualdade em situações específicas que são atendidas pelo SVM: função custo convexa, restrições afins e condições de Karush-Kuhn-Tucker (KKT) satisfeitas.

- Condições de KKT para o SVM:

$$\begin{aligned}\alpha_i &\geq 0, \forall i, \\ (\mathbf{w}^\top \mathbf{x}_i + b)y_i - 1 &\geq 0, \forall i, \\ \alpha_i [(\mathbf{w}^\top \mathbf{x}_i + b)y_i - 1] &= 0, \forall i.\end{aligned}$$

Máquinas de Vetores Suporte

- **Prova da desigualdade max-min** (para mínimos e máximos existentes):

$$\min_y f(x, y) \leq f(x, y), \text{ aplica } \max_x \text{ em ambos os lados:}$$

$$\max_x \min_y f(x, y) \leq \max_x f(x, y), \text{ aplica } \min_y \text{ em ambos os lados:}$$

$$\min_y \max_x \min_y f(x, y) \leq \min_y \max_x f(x, y).$$

Como $\max_x \min_y f(x, y)$ é independente de y :

$$\min_y \max_x \min_y f(x, y) = \max_x \min_y f(x, y).$$

Logo, pela desigualdade anterior:

$$\max_x \min_y f(x, y) \leq \min_y \max_x f(x, y).$$

Máquinas de Vetores Suporte

- Novo problema de otimização:

$$\max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}) = \max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i].$$

Máquinas de Vetores Suporte

- Novo problema de otimização:

$$\max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} \mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}) = \max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \alpha_i [1 - (\mathbf{w}^\top \mathbf{x}_i + b) y_i].$$

- O mínimo com relação a \mathbf{w} , b é obtido diferenciando \mathcal{J} :

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^N \alpha_i \mathbf{x}_i y_i = 0, \rightarrow \mathbf{w} = \sum_{i=1}^N \alpha_i \mathbf{x}_i y_i,$$

$$\frac{\partial \mathcal{J}}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0.$$

- Substituímos $\mathbf{w} = \sum_{i=1}^N \alpha_i \mathbf{x}_i y_i$ na função $\mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha})$:

$$\mathcal{J}(\mathbf{w}, b, \boldsymbol{\alpha}) = \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j (\mathbf{x}_i^\top \mathbf{x}_j) - b \overbrace{\sum_{i=1}^N \alpha_i y_i}^0$$

Máquinas de Vetores Suporte

Formulação linear dual do SVM

- Problema de otimização com restrições lineares:

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j (\mathbf{x}_i^\top \mathbf{x}_j) \\ \text{s. a. } \quad & \alpha_i \geq 0, \forall i, \quad \sum_{i=1}^N \alpha_i y_i = 0. \end{aligned}$$

- **Otimização quadrática convexa com restrições lineares.**
- **Programação quadrática** (QP - *quadratic programming*).
- Os parâmetros w e o bias b não aparecem na otimização.

Máquinas de Vetores Suporte

- Lembrando das condições de KKT para o SVM:

$$\alpha_i \geq 0, \forall i,$$

$$(\mathbf{w}^\top \mathbf{x}_i + b)y_i - 1 \geq 0, \forall i,$$

$$\alpha_i [(\mathbf{w}^\top \mathbf{x}_i + b)y_i - 1] = 0, \forall i.$$

- A última restrição garante que :
 - Se $(\mathbf{w}^\top \mathbf{x}_i + b)y_i > 1$, temos $\alpha_i = 0$.
 - Se $\alpha_i > 0$, temos $(\mathbf{w}^\top \mathbf{x}_i + b)y_i = 1$, ou seja, o padrão \mathbf{x}_i está sobre os hiperplanos de máxima margem.

Máquinas de Vetores Suporte

Formulação linear dual do SVM

- Somente um subconjunto \mathcal{S} de N_S coeficientes α_i , relacionados aos padrões \mathbf{x}_i (**vetores suporte**), serão diferentes de zero.
- Os parâmetros e viés ótimos são dados por:

$$\mathbf{w}_* = \sum_{i \in \mathcal{S}} \alpha_i \mathbf{x}_i y_i, \quad b_* = \frac{1}{N_S} \sum_{i \in \mathcal{S}} (y_i - \mathbf{w}_*^\top \mathbf{x}_i).$$

- Predições para um novo padrão \mathbf{x}_j são realizadas como abaixo:

$$\hat{y}_j = \text{sign}(\mathbf{w}_*^\top \mathbf{x}_j + b_*)$$

$$\hat{y}_j = \text{sign} \left(\left(\sum_{i \in \mathcal{S}} \alpha_i y_i \mathbf{x}_i^\top \right) \mathbf{x}_j + b_* \right).$$

Agenda

- ① SVM linear com hard margin
- ② SVM linear com soft margin
- ③ SVM não-linear
- ④ Tópicos adicionais
- ⑤ Referências

Máquinas de Vetores Suporte


Formulação linear primal do SVM com variáveis de folga

- Variante conhecida por *soft margin*:

$$\min_{w,b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

s. a. $(\mathbf{w}^\top \mathbf{x}_i + b)y_i \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i \in \{1, \dots, N\}.$

- Para valores $\xi_i > 1$ o padrão \mathbf{x}_i será erroneamente classificado.




Máquinas de Vetores Suporte


Formulação linear primal do SVM com variáveis de folga

- O termo $C \sum_{i=1}^N \xi_i$ equivale à regularização L1 para $C = \frac{1}{\lambda}$.
- O hiperparâmetro $C \geq 0$ controla a taxa de exemplos errados.
- Para $C \rightarrow 0$, o modelo é menos esparsos, uma margem maior é obtida ao custo de mais exemplos erroneamente classificados.
- Para $C \rightarrow \infty$, o modelo é mais esparsos, uma margem menor é obtida, mas mais padrões são corretamente classificados.


$C=1000$



$C=10$



$C=0.1$



Máquinas de Vetores Suporte

Formulação linear dual do SVM com variáveis de folga

- Problema de otimização com restrições lineares:

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j (\mathbf{x}_i^\top \mathbf{x}_j) \\ \text{s. a.} \quad & 0 \leq \alpha_i \leq C, \forall i, \quad \sum_{i=1}^N \alpha_i y_i = 0. \end{aligned}$$

- Os parâmetros e viés ótimos são dados por:

$$\mathbf{w}_* = \sum_{i=1}^N \alpha_i \mathbf{x}_i y_i, \quad b_* = \text{median} (y_i - \mathbf{w}_*^\top \mathbf{x}_i), \forall i \in \mathcal{S}_*,$$

em que \mathcal{S}_* é o subconjunto em que $0 < \alpha_i < C$.

- Algumas implementações computam b_* pela média dos erros.

Agenda

- ① SVM linear com hard margin
- ② SVM linear com soft margin
- ③ SVM não-linear
- ④ Tópicos adicionais
- ⑤ Referências

Máquinas de Vetores Suporte

- **Problema:** Como transformar um classificador linear em um não-linear?

Máquinas de Vetores Suporte

- **Problema:** Como transformar um classificador linear em um não-linear?
- **Ideia:** Criar novos atributos a partir de uma transformação não-linear $\phi(\mathbf{x})$.

→ **Exemplo:**

Padrão original: $\mathbf{x} = [x_1, x_2]^\top$


Padrão transformado: $\phi(\mathbf{x}) = [x_1, x_2, x_1^2, x_2^2]^\top$

Máquinas de Vetores Suporte

- **Problema:** Como transformar um classificador linear em um não-linear?
- **Ideia:** Criar novos atributos a partir de uma transformação não-linear $\phi(\mathbf{x})$.
 - **Exemplo:**
 - Padrão original: $\mathbf{x} = [x_1, x_2]^\top$
 - Padrão transformado: $\phi(\mathbf{x}) = [x_1, x_2, x_1^2, x_2^2]^\top$
- O novo espaço formado por $\phi(\cdot)$ é chamado de **espaço de atributos** (*feature space*).


Máquinas de Vetores Suporte

- Esperamos que nesse novo espaço os dados passem a ser linearmente separáveis (ou próximo disso).



Máquinas de Vetores Suporte

- Esperamos que nesse novo espaço os dados passem a ser linearmente separáveis (ou próximo disso).



- **Problema:** Como encontrar um mapeamento $\phi(\cdot)$ adequado?
- **Problema:** Espaços de alta dimensão resultam em maior custo computacional e um maior número de parâmetros.

Máquinas de Vetores Suporte

Truque do kernel (*kernel trick*)

- Produtos internos no espaço de atributos são substituídos por uma **função de kernel**:

$$k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j).$$

- Não computamos $\phi(\cdot)$, somente a função de kernel $k(\cdot)$.
- Exemplo:** Sejam $\mathbf{x}_i = [x_{i1}, x_{i2}]^\top$ e $\mathbf{x}_j = [x_{j1}, x_{j2}]^\top$:

$$k(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^3$$

$$k(\mathbf{x}_i, \mathbf{x}_j) = (x_{i1}x_{j1} + x_{i2}x_{j2})^3$$

$$k(\mathbf{x}_i, \mathbf{x}_j) = x_{i1}^3x_{j1}^3 + 3x_{i1}^2x_{j1}^2x_{i2}x_{j2} + 3x_{i2}^2x_{j2}^2x_{i1}x_{j1} + x_{i2}^3x_{j2}^3$$

$$k(\mathbf{x}_i, \mathbf{x}_j) = [x_{i1}^3, \sqrt{3}x_{i1}^2x_{i2}, \sqrt{3}x_{i2}^2x_{i1}, x_{i2}^3][x_{j1}^3, \sqrt{3}x_{j1}^2x_{j2}, \sqrt{3}x_{j2}^2x_{j1}, x_{j2}^3]^\top$$

$$k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j).$$

Máquinas de Vetores Suporte

Formulação dual do SVM com soft margin

- Problema de otimização original (caso linear):

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s. a.} \quad & 0 \leq \alpha_i \leq C, \forall i, \quad \sum_{i=1}^N \alpha_i y_i = 0. \end{aligned}$$

- Predições para um novo padrão \mathbf{x}_j são realizadas como abaixo:

$$\hat{y}_j = \text{sign} \left(\left(\sum_{i \in \mathcal{S}} \alpha_i y_i \mathbf{x}_i^\top \right) \mathbf{x}_j + b_* \right).$$

Máquinas de Vetores Suporte

Formulação dual do SVM com soft margin

- Substituímos \mathbf{x} pelo mapeamento não-linear $\phi(\mathbf{x})$:

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) \\ \text{s. a. } \quad & 0 \leq \alpha_i \leq C, \forall i, \quad \sum_{i=1}^N \alpha_i y_i = 0. \end{aligned}$$

- Predições para um novo padrão \mathbf{x}_j são realizadas como abaixo:

$$\hat{y}_j = \text{sign} \left(\left(\sum_{i \in \mathcal{S}} \alpha_i y_i \phi(\mathbf{x}_i)^\top \right) \phi(\mathbf{x}_j) + b_* \right).$$

Máquinas de Vetores Suporte

Formulação do SVM com soft margin e uso de kernels

- Aplicamos o truque de kernel ($k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$):

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) \\ \text{s. a.} \quad & 0 \leq \alpha_i \leq C, \forall i, \quad \sum_{i=1}^N \alpha_i y_i = 0. \end{aligned}$$

- Predições para um novo padrão \mathbf{x}_j são realizadas como abaixo:

$$\begin{aligned} \hat{y}_j &= \text{sign} \left(b_* + \sum_{i \in \mathcal{S}} \alpha_i y_i k(\mathbf{x}_i, \mathbf{x}_j) \right), \\ b_* &= \text{median} \left(y_m - \sum_{i \in \mathcal{S}} \alpha_i y_i k(\mathbf{x}_i, \mathbf{x}_m) \right), \forall m \in \mathcal{S}_*. \end{aligned}$$

Máquinas de Vetores Suporte

- **Observação:** Os parâmetros w não podem mais ser escritos em função de uma combinação linear dos vetores suporte.
- Os vetores suporte (e suas respectivas saídas) devem ser mantidos para realizar predições.
- Como o número de vetores suporte é usualmente menor que N , dizemos que o SVM é um **modelo não-paramétrico esparsos**.

Máquinas de Vetores Suporte

Exemplos de função de kernel

- Kernel linear: $k(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$.
- Kernel polinomial: $k(\mathbf{x}_i, \mathbf{x}_j) = (Q + \mathbf{x}_i^\top \mathbf{x}_j)^P$.
- Kernel Gaussiano (RBF): $k(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$.
- Kernel exponencial: $k(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|)$.
- Kernel sigmoidal: $k(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \alpha)$.

Máquinas de Vetores Suporte

Teorema de Mercer

- Todo kernel válido corresponde ao produto interno em um espaço de atributos.
- Um kernel é válido caso sua matriz de kernel \mathbf{K} (Gram matrix) seja definida positiva ($\mathbf{z}^\top \mathbf{K} \mathbf{z}$ é positivo para \mathbf{z} não-nulo):

$$\mathbf{K} \in \mathbb{R}^{N \times N}, \quad K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j), \forall i, j.$$

Máquinas de Vetores Suporte

Teorema de Mercer


- Todo kernel válido corresponde ao produto interno em um espaço de atributos.
- Um kernel é válido caso sua matriz de kernel \mathbf{K} (Gram matrix) seja definida positiva ($\mathbf{z}^\top \mathbf{K} \mathbf{z}$ é positivo para \mathbf{z} não-nulo):

$$\mathbf{K} \in \mathbb{R}^{N \times N}, \quad K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j), \forall i, j.$$

- O espaço de atributos correspondente de um kernel pode ter dimensionalidade muito alta.
 - O kernel polinomial de ordem P corresponde a um espaço com $\binom{D+P}{P}$ dimensões, em que D é a dimensão original dos dados.
 - O kernel Gaussiano corresponde a um espaço de atributos infinitamente grande.

Máquinas de Vetores Suporte

- **Observação:** Fronteiras de separação lineares no espaço de atributos mapeado pelo kernel correspondem a fronteiras não-lineares no espaço original dos dados.



Máquinas de Vetores Suporte


- O desempenho do SVM depende da escolha do hiperparâmetro de regularização C e do(s) hiperparâmetro(s) da função de kernel (γ , P , $Q...$).
- **Problema:** Como escolher valores adequados para esses hiperparâmetros?

Máquinas de Vetores Suporte

- O desempenho do SVM depende da escolha do hiperparâmetro de regularização C e do(s) hiperparâmetro(s) da função de kernel (γ , P , Q ...).
- **Problema:** Como escolher valores adequados para esses hiperparâmetros?
- **Ideia:** Grid-search para valores candidatos.
 - Considerando o kernel Gaussiano, usualmente testamos os valores abaixo:


$$C \in \{2^{-5}, 2^{-3}, 2^{-1}, \dots, 2^{13}, 2^{15}\},$$
$$\gamma \in \{2^{-15}, 2^{-13}, 2^{-11}, \dots, 2^1, 2^3\}.$$

SVM (pontos escuros são os SV)




- Kernel RBF, $C = 2^{-5}$, $\gamma = 2$ (valor de C muito pequeno).
- 238 vetores suporte de 241 dados de treinamento (90.76%).
- Taxa de erro no treinamento: 20.33%, taxa de erro no teste: 23.73%.

SVM (pontos escuros são os SV)



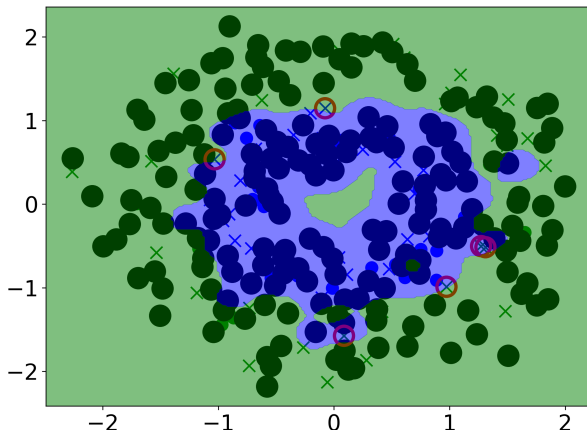
- Kernel RBF, $C = 2^{15}$, $\gamma = 2$ (valor de C muito grande).
- 35 vetores suporte de 241 dados de treinamento (14.52%).
- Taxa de erro no treinamento: 0%, taxa de erro no teste: 11.86%.

SVM (pontos escuros são os SV)




- Kernel RBF, $C = 2^5$, $\gamma = 2^{-5}$ (valor de γ muito pequeno).
- 82 vetores suporte de 241 dados de treinamento (34.02%).
- Taxa de erro no treinamento: 7.05%, taxa de erro no teste: 6.78%.

SVM (pontos escuros são os SV)



- Kernel RBF, $C = 2^5$, $\gamma = 2^5$ (valor de γ muito grande).
- 193 vetores suporte de 241 dados de treinamento (80.08%).
- Taxa de erro no treinamento: 0%, taxa de erro no teste: 10.17%.

SVM (pontos escuros são os SV)



- Kernel RBF, $C = 2^5$, $\gamma = 2$ (valores otimizados via grid-search).
- 44 vetores suporte de 241 dados de treinamento (18.26%).
- Taxa de erro no treinamento: 3.32%, taxa de erro no teste: 5.08%.

Agenda

- ① SVM linear com hard margin
- ② SVM linear com soft margin
- ③ SVM não-linear
- ④ Tópicos adicionais
- ⑤ Referências

Tópicos adicionais

- Support Vector Regression (SVR).
- Least Squares SVM (LSSVM).
- Processos Gaussianos (alternativa Bayesiana).

Tópicos adicionais

- Support Vector Regression (SVR).
- Least Squares SVM (LSSVM).
- Processos Gaussianos (alternativa Bayesiana).
 - Regressão não-linear com ruído Gaussiano:

$$\begin{aligned}y_i &= f(\mathbf{x}_i) + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma_n^2), \\ \mathbf{f} &= f(\mathbf{X}) \sim \mathcal{N}(\mathbf{f} | \mathbf{0}, \mathbf{K}), \\ p(y_* | \mathbf{x}_*, \mathbf{X}, \mathbf{y}) &= \mathcal{N}(\mu_*, \sigma_*^2 + \sigma_n^2), \\ &\begin{cases} \mu_* = \mathbf{k}_{f_*}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}, \\ \sigma_*^2 = k_{**} - \mathbf{k}_{f_*}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_{f_*}. \end{cases}\end{aligned}$$

→ Otimização dos hiperparâmetros θ via gradiente:

$$\log p(\mathbf{y} | \mathbf{X}, \theta) = -\frac{1}{2} \underbrace{\log |\mathbf{K} + \sigma_n^2 \mathbf{I}|}_{\text{capacidade do modelo}} - \frac{1}{2} \underbrace{\mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}}_{\text{ajuste aos dados}} - \frac{N}{2} \log(2\pi).$$

Agenda

- ① SVM linear com hard margin
- ② SVM linear com soft margin
- ③ SVM não-linear
- ④ Tópicos adicionais
- ⑤ Referências

Referências bibliográficas

- **Cap. 14** - MURPHY, Kevin P. **Machine learning: a probabilistic perspective**, 2012.
- **Cap. 7** - BISHOP, C. **Pattern recognition and machine learning**, 2006.
- **Cap. 6** - HAYKIN, S. **Neural networks and learning machines**, 2009.